

# 钱佳辰

香港城市大学计算机科学硕士生

Jiachen Qian

可信人工智能 | 多模态大模型 | 智能体安全 | 对抗防御

+86 138 6221 5800 | 72510756@cityu-dg.edu.cn | Homepage | Google Scholar | GitHub

## 个人简介

香港城市大学计算机科学硕士生，本科毕业于南京信息工程大学软件工程专业。研究聚焦于可信多模态人工智能与智能体安全，重点关注购物智能体中的视觉对抗失效、Agentic Recommender 中的长时记忆投毒，以及 LLM 的结构敏感行为分析。已围绕多模态智能体安全完成两篇独立一作论文，参与 1 篇关于大模型顺序敏感性与确定性结构重建的 arXiv 预印本，并有 1 篇面向社交媒体篡改图像识别大模型攻击的 ECCV 在投论文，具备从问题定义、方法设计、实验构建到论文撰写的完整科研训练。

## 研究方向

可信多模态人工智能、多模态大模型智能体、智能体安全、对抗攻击与防御、长时记忆投毒与防护、LLM 行为分析与结构探测、篡改图像识别大模型安全、可靠决策机制。

## 教育背景

### 香港城市大学

中国香港

计算机科学硕士

2025 年 9 月 – 2027 年 6 月 (预计)

- GPA: 3.3/4.0
- 当前研究围绕可信多模态智能体、记忆增强 AI 系统以及对抗鲁棒性展开。

### 南京信息工程大学

南京, 中国

软件工程学士

2021 年 9 月 – 2025 年 6 月

## 科研项目

### 多模态购物智能体安全研究

中国香港

香港城市大学研究生科研项目

2025 年 9 月 – 至今

- 研究价格约束场景下多模态购物智能体的可信决策问题，关注不可感知的视觉线索如何覆盖显式文本价格证据。
- 在 *Penny Wise, Pixel Foolish* 中提出 Visual Dominance Hallucination 失效现象，并设计 PriceBlind 隐形攻击框架，在保持像素级视觉保真的同时诱导模型违反“购买最便宜商品”的约束。
- 在 E-ShopBench 上实现约 80% 白盒攻击成功率，并在 GPT-4o、Gemini-1.5-Pro、Claude-3.5-Sonnet 上取得 35–41% 迁移攻击成功率，同时分析 Verify-then-Act 与鲁棒编码器防御效果。

### 长时记忆推荐智能体安全研究

中国香港

香港城市大学研究生科研项目

2025 年 9 月 – 至今

- 研究 Agentic Recommender 长时规划中的安全风险，关注多模态长时记忆如何成为后续推荐操控的攻击面。
- 在 *Visual Inception* 中设计视觉记忆投毒攻击，将休眠触发器植入用户上传图像，并在未来推荐规划阶段劫持推理链而无需 prompt injection。
- 提出 CognitiveGuard 双进程防御，结合扩散式输入净化与反事实一致性验证，将 Goal-Hit Rate 从约 85% 降至约 10%，并支持不同延迟开销配置。

### 社交媒体篡改图像识别大模型攻击研究

中国深圳

深圳北理工莫斯科大学在研项目

2026 年

- 围绕社交媒体场景中的篡改图像识别大模型开展安全研究，关注识别导向大模型在真实在线传播环境中的对抗脆弱性。
- 设计面向篡改图像识别大模型的攻击流程，分析攻击对模型识别可靠性与判别行为的影响。
- 已形成 1 篇 ECCV 在投论文，目前处于审稿阶段。

## 学术亮点

- 已形成两篇独立一作多模态智能体安全论文、1 篇 arXiv 合作预印本与 1 篇 ECCV 在投论文。
- 围绕视觉对抗攻击、多模态记忆投毒与智能体可靠决策建立了清晰研究主线。

- 能够将安全威胁模型转化为可量化的攻击与防御框架，并在前沿多模态模型与推荐智能体上开展系统评测。
- 具备从问题定义、方法设计、实验构建、结果分析到论文撰写的独立科研能力。

## 论文与稿件

### 独立一作论文

- **Qian, Jiachen** and Zhaolu Kang. "Penny Wise, Pixel Foolish: Bypassing Price Constraints in Multimodal Agents via Visual Adversarial Perturbations." *Findings of ACL 2026*, 已录用; arXiv:2604.16515.  
独立一作; 多模态购物智能体价格约束绕过攻击与防御
- **Qian, Jiachen**. "Visual Inception: Compromising Long-term Planning in Agentic Recommenders via Multimodal Memory Poisoning." *ACL 2026 Main Conference*, 已录用; arXiv:2604.16966.  
独立一作; 面向 Agentic Recommender 的长时记忆投毒与防御

### 合作预印本

- He, Yingjie, Zhaolu Kang, Kehan Jiang, **Qian, Jiachen**, et al. "How Order-Sensitive Are LLMs? OrderProbe for Deterministic Structural Reconstruction." *arXiv preprint arXiv:2601.08626*, 2026.  
共同作者; LLM 顺序敏感性与确定性结构重建

### 在投论文

- Manuscript on attacks against large models for tampered social-media image detection. Submitted to *ECCV*, under review, 2026.  
合作研究; 社交媒体篡改图像识别大模型攻击

## 学术服务

- 担任 *IEEE Transactions on Information Forensics and Security (TIFS)* 审稿人。

## 荣誉奖项

- 2025 届: 南京信息工程大学本科学院优秀毕业生、校级优秀毕业生
- 2021 – 2022 学年: 一等奖学金
- 2022 – 2023 学年: 三等奖学金
- 2023 – 2024 学年: 三等奖学金

## 技术能力

- 编程语言: Python、C++、SQL
- AI 与科研工具: PyTorch、CUDA、Scikit-learn、LLM/VLM 开发、多模态智能体评测、篡改图像识别模型攻击分析
- 科研工程能力: Codex、AI 辅助编程 workflow、实验自动化、对抗攻击与防御评测、可复现实验分析
- 研究主题: 可信人工智能、多模态智能体安全、记忆增强智能体安全、篡改图像识别大模型攻击、对抗攻击与防御